Persiapan Data

Kemiskinan merupakan masalah yang masih menjadi trending topic di seluruh negara, terutama di negara berkembang seperti Indonesia. Pengentasan kemiskinan merupakan tujuan pertama dari Sustainable Development Goals (SDGs) yang digagas oleh United Nations Development Programme (UNDP). Masalah kemiskinan juga seringkali dijadikan indikator untuk mengevaluasi kinerja pemerintah dalam meningkatkan taraf hidup rakyat.

```
In [1]: %matplotlib inline
    import numpy as np
    import pandas as pd
    import seaborn as sns
    sns.set(style='darkgrid')
    import os
    import sys
    import json

from pandas.io.stata import StataReader

from matplotlib import pyplot as plt
    from IPython.display import display
    from sklearn.model_selection import train_test_split

# Add our local functions to the path
    sys.path.append(os.path.join(os.pardir, 'src'))
```

Load data

Load data .sav menggunakan paket pyreadstat sedangkan load .csv cukup dengan menggunakan fungsi bawaan pandas.read_csv

```
In [2]: import pyreadstat
    df_kor_rt, meta_kor_rt = pyreadstat.read_sav("14_ssn_202003_kor_rt.sav")
    df_kor_ind1, meta_kor_ind1 = pyreadstat.read_sav("14_ssn_202003_kor_ind1.sav")
    df_kor_ind2, meta_kor_ind2 = pyreadstat.read_sav("14_ssn_202003_kor_ind2.sav")
    df_kp41, meta_kp41 = pyreadstat.read_sav("14_ssn_202003_kp41.sav")
    df_kp42, meta_kp42 = pyreadstat.read_sav("14_ssn_202003_kp42.sav")
    df_kp43, meta_kp43 = pyreadstat.read_sav("14_ssn_202003_kp43.sav")
    riau_kons_41 = pd.read_csv("riau_kons.csv")
    riau_kons_42 = pd.read_csv("riau_kons_42.csv")

In [3]: print (df_kor_rt.shape, df_kor_ind1.shape, df_kor_ind2.shape)
    print (df_kp41.shape, df_kp42.shape, df_kp43.shape)
    print (riau_kons_41.shape, riau_kons_42.shape)

    (8182, 240) (31721, 156) (31721, 157)
    (417696, 27) (340036, 26) (8182, 22)
    (8182, 175) (8182, 103)
```

Menggabungkan/merge data

Menggabungkan data kor rumah tangga dengan data pengeluaran per kapita rumah tangga Menggabungkan data dengan fungsi merge dari pandas

```
In [4]: # Menggabungkan data kor dengan data pengeluaran per kapita
        riau_rt = df_kor_rt.merge(df_kp43[["renum", "kapita", "weind"]], on='renum', how='left')
        riau rt.shape
Out[4]: (8182, 242)
In [5]: # Memberikan label miskin berdasarkan garis kemiskinan maret 2020
        # perkotaan 570462, perdesaan 526431
        # perkotaan r105 =1, perdesaan r105=2
        riau_rt['miskin'] = np.where((((riau_rt['r105'] == 1) & (riau_rt['kapita'] < 570462)) |
                                      ((riau_rt['r105'] == 2) & (riau_rt['kapita'] < 526431))), True, False)
        riau_rt.shape
Out[5]: (8182, 243)
In [6]: # Menggabungkan data kor riau dengan data variabel konsumsi komoditas
        riau_rt = riau_rt.merge(riau_kons_41, on='renum', how='left')
        riau_rt = riau_rt.merge(riau_kons_42, on='renum', how='left')
        riau_rt.shape
Out[6]: (8182, 519)
```

```
In [7]: # memecah menjadi sampel kota dan desa
         # untuk mengecek apakah sesuai dengan p0 perkotaan dan perdesaan
         riau_rt_kota = riau_rt[riau_rt['r105'] == 1]
         riau_rt_desa = riau_rt[riau_rt['r105'] == 2]
         print(riau_rt_kota.shape, riau_rt_desa.shape)
          (3030, 519) (5152, 519)
         Mengecek apakah angka kemiskinan sudah sesuai
In [8]: # persentase penduduk miskin riau (perkotaan+perdesaan) adalah 6,82
         p0 = riau_rt.groupby('miskin').agg({'weind': 'sum'}).sort_values('weind', ascending=False)
         p0['weind']=(p0['weind']*100)/p0['weind'].sum()
         print(p0)
                      weind
         miskin
         False
                  93.180994
                   6.819006
         True
In [9]: riau_rt['miskin'].value_counts().plot.bar()
Out[9]: <AxesSubplot:>
           8000
           7000
           6000
           5000
          4000
           3000
           2000
           1000
             0
In [10]: riau_rt['miskin'].value_counts()
Out[10]: False
                   7780
                    402
         Name: miskin, dtype: int64
In [11]: # persentase penduduk miskin riau (perkotaan) adalah 6,12
         p0_kota = riau_rt_kota.groupby('miskin').agg({'weind': 'sum'}).sort_values('weind', ascending=False)
         p0_kota['weind']=(p0_kota['weind']*100)/p0_kota['weind'].sum()
         print(p0_kota)
                      weind
         miskin
         False
                  93.875877
                  6.124123
         True
In [12]: # persentase penduduk miskin riau (perdesaan) adalah 7,29
         p0_desa = riau_rt_desa.groupby('miskin').agg({'weind': 'sum'}).sort_values('weind', ascending=False)
         p0_desa['weind']=(p0_desa['weind']*100)/p0_desa['weind'].sum()
         print(p0_desa)
                      weind
         miskin
                  92.711005
         False
         True
                   7.288995
In [13]: riau_rt.head()
Out[13]:
             D_R r101 r102 r105 nuinfort r1701 r1702 r1703 r1704 r1705 ... kons_300 kons_301 kons_302 kons_303 kons_305 kons_306 kons_307 kons_308
                                                                 5.0 ...
                                                                               0
                                                                                       0
                                                                                                                  0
                  14.0
                       1.0
                            2.0
                                    2.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                                                                           0
                                                                                                                                    0
                 14.0
                       1.0
          1
                            2.0
                                    1.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                 1.0 ...
                                                                              0
                                                                                                0
                                                                                                         0
                                                                                                                  0
                                                                                                                           0
                                                                                                                                    0
                                                                 5.0 ...
                                                                              0
                                                                                                                  0
                  14.0
                       1.0
                            2.0
                                    2.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                                       1
                                                                              0
                                                                                                0
                                                                                                                  0
                                                                                                                           0
                                                                                                                                    0
          3
                  14.0
                       1.0
                            2.0
                                    2.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                 5.0 ...
                                                                                       0
                                                                                                         0
          4
                  14.0
                       1.0
                            2.0
                                    1.0
                                          1.0
                                                1.0
                                                      1.0
                                                                 5.0 ...
                                                                               0
                                                                                       0
                                                                                                0
                                                                                                          0
                                                                                                                  0
                                                                                                                           0
                                                                                                                                    0
         5 rows × 519 columns
```

Build derived features from individual data

- · Number of children (age 10 and under) in household
- Number of males in household (over 10 years old)
- · Number of females in household (over 10 years old)
- Jumlah anggota keluarga yang dapat membaca dan menulis huruf latin/alfabe
- · Jumlah anggota keluarga yang bekerja selama seminggu terakhir
- · Jumlah anggota keluarga yang pernah menggunakan internet dalam tiga bulan terakhir

```
In [14]: |# Menggabungkan data individu
         riau_ind = pd.concat([df_kor_ind1, df_kor_ind2], axis=1)
         riau_ind.shape
Out[14]: (31721, 313)
In [15]: # Membuang kolom yang duplikat
         riau_ind = riau_ind.loc[:,~riau_ind.columns.duplicated()]
         riau_ind.shape
Out[15]: (31721, 300)
In [ ]: # riau_ind.to_csv('riau_ind.csv', index = False, header=True)
In [ ]: # riau_rt.r304.sum().astype(int)
In [ ]: # (riau ind.r407 >= 10).sum().astype(int)
In [ ]: # Number of children (age 10 and under) in household
         # riau_ind.groupby(['renum'])[['der_nchild10under']].agg('sum')
In [16]: def add_derived_feature(df_rt,
                                   df_ind,
                                   feature_name,
                                   value,
                                   ):
              '''Menambahkan variabel baru ke data rumah tangga'''
              df_ind['der_' + feature_name] = value
              value2 = df_ind.groupby(['renum'])[['der_' + feature_name]].agg('sum')
              value2['renum'] = value2.index
              value2.reset_index(drop=True,level=0, inplace=True)
              df_rt = df_rt.merge(value2, on='renum', how='left')
              return df_rt
In [17]: # IDN - Number of children (Under 10) in household
         value = pd.DataFrame(riau_ind.r407 < 10).sum(level=0).astype(int)</pre>
         riau_rt = add_derived_feature(riau_rt, riau_ind, 'nchild10under', value)
         riau_rt.head()
Out[17]:
             D_R r101 r102 r105 nuinfort r1701 r1702 r1703 r1704 r1705 ... kons_301 kons_302 kons_303 kons_305 kons_306 kons_307 kons_308 kons_308 kons_309
          0
                             2.0
                                                                                0
                  14.0
                                     2.0
                                          5.0
                                                                  5.0 ...
                                                                                        0
                                                                                                                    0
                                                                                                                            0
          1
                  14.0
                        1.0
                             2.0
                                    1.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                  1.0 ...
                                                                                1
                                                                                        0
                                                                                                 0
                                                                                                           0
                                                                                                                   0
                                                                                                                            0
                                                                                                                                      0
                                                                                                                                               0
          2
                                                                                                           0
                                                                                                                   0
                                                                                                                            0
                                                                                                                                      0
                                                                                                                                               0
                  14.0
                        1.0
                            2.0
                                    2.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                  5.0 ...
                                                                                1
                                                                                        0
                                                                                                 0
          3
                  14.0
                        1.0
                             2.0
                                    2.0
                                          5.0
                                                5.0
                                                      5.0
                                                            5.0
                                                                  5.0 ...
                                                                                0
                                                                                        0
                                                                                                 0
                                                                                                           0
                                                                                                                   0
                                                                                                                             0
                                                                                                                                      0
                                                                                                                                               0
                  14.0
                        1.0
                             2.0
                                    1.0
                                          1.0
                                                1.0
                                                      1.0
                                                            5.0
                                                                  5.0 ...
                                                                                                                    0
                                                                                                                             0
         5 rows x 520 columns
In [18]: # IDN - Number of males and females in household >= 10
         value = pd.DataFrame((riau_ind.r407 >= 10) & (riau_ind.r405 == 1)).sum(level=0).astype(int)
         riau_rt = add_derived_feature(riau_rt, riau_ind, 'nmalesover10', value)
         riau_rt.shape
Out[18]: (8182, 521)
In [19]: # IDN - Number of males and females in household >= 10
         value = pd.DataFrame((riau_ind.r407 >= 10) & (riau_ind.r405 == 2)).sum(level=0).astype(int)
         riau_rt = add_derived_feature(riau_rt, riau_ind, 'nfemalesover10', value)
         riau_rt.shape
Out[19]: (8182, 522)
In [20]: # IDN - Jumlah anggota rumah tangga yang dapat membaca dan menulis huruf latin/alfabet
         value = pd.DataFrame(riau_ind.r609 == 1).sum(level=0).astype(int)
         riau_rt = add_derived_feature(riau_rt, riau_ind, 'nliterate', value)
         riau_rt.shape
Out[20]: (8182, 523)
```

```
In [21]: # IDN - Jumlah anggota rumah tangga yang bekerja selama seminggu terakhir
value = pd.DataFrame(riau_ind.r702_a == 'A').sum(level=0).astype(int)
           riau_rt = add_derived_feature(riau_rt, riau_ind, 'nbekerja', value)
Out[21]: (8182, 524)
In [22]: | # IDN - Jumlah anggota rumah tangga yang pernah menggunakan internet dalam tiga bulan terakhir
           value = pd.DataFrame(riau_ind.r808 == 1).sum(level=0).astype(int)
           riau_rt = add_derived_feature(riau_rt, riau_ind, 'ninternetpast3mo', value)
           riau_rt.shape
Out[22]: (8182, 525)
           Mengecek variabel konsumi mana yang paling banyak di konsumsi
           Keterangan: variabel dengan awalan kons
In [23]: # Filter consumables and group by poor/non-poor
           consumable_columns = [x for x in riau_rt.columns if x.startswith('kons_')]
           consumables = (riau_rt.groupby('miskin')[consumable_columns].sum().T)
           consumables.columns = ['tidak_miskin', 'miskin']
           consumables['total'] = consumables.sum(axis=1)
           consumables['percent'] = consumables.total / riau_rt.shape[0]
           # Display the top 10 most common consumables
           consumables.sort_values('percent', ascending=False).head(20)
Out[23]:
                      tidak miskin miskin total percent
            kons_232
                             7772
                                     398 8170 0.998533
            kons_235
                            7719
                                     397 8116 0.991934
                             7632
                                     402 8034 0.981912
              kons 2
            kons_197
                             7589
                                     381 7970 0.974089
            kons_134
                             7519
                                     396 7915 0.967367
            kons 233
                             7456
                                     372 7828 0.956734
             kons_92
                             7428
                                     389
                                         7817 0.955390
            kons_122
                             7367
                                     387
                                         7754 0.947690
            kons 126
                             7366
                                     366 7732 0.945001
            kons_227
                             7360
                                     350 7710 0.942312
            kons_276
                             7317
                                     360 7677 0.938279
In [24]: # Plot the top 10 most common consumables
           (consumables.total
                         .sort_values(ascending=False)
                         .head(20)
                         .sort_values(ascending=True).plot.barh());
            kons_232
kons_235
            kons_2
kons_197
kons_134
kons_233
            kons_233
kons_92
kons_122
kons_126
kons_227
kons_276
kons_272
kons_216
kons_271
kons_225
kons_299
             kons_299
kons_207
             kons_63
kons_93
                              2000
                                     3000
                                          4000
                                                5000
                                                      6000
                                                            7000
 In [ ]: consumables['difference'] = (consumables.tidak_miskin - consumables.miskin) / consumables.total
```

Create Train/Test Split and Save Data

display(consumables.sort_values('difference', ascending=False).head(20))

Display the top 20 most common consumables

As a final step, we want to split the data into training and test sets which will be used by all of the algorithms. We'll reserve 25% of the data as a test set.

Tambahan

Membuat data khusus dummy variabel data konsumsi

- riau_kons dari kp41
- · riau kons 42 dari kp42
- Keterangan: uncomment untuk menjalankan (ctrl+/)

riau_kons dari kp41

```
In [ ]: # riau_kons = pd.DataFrame(riau_rt["renum"], columns=['renum'])
         # riau_kons.head()
In [ ]: # for x in range(1,189):
               riau_kons['kons_'+ str(x)] = 0
         # riau_kons.shape
In [ ]: # riau_kons.head()
In [ ]: # riau_kons.loc[riau_kons['renum'] == 46056]
In [ ]: # riau_kons.loc[riau_kons['renum'] == 46056, 'kons_'+ str(1)] = 0
In [ ]: # import warnings
         # warnings.filterwarnings('ignore')
In [ ]: # for i in range(1):
               riau\_kons.loc[riau\_kons['renum'] == df\_kp41.loc[i, "renum"], 'kons\_' + str(df\_kp41.loc[i, "kode"].astype(int))] = 0 \\ print(df\_kp41.loc[i, "renum"], 'kons\_' + str(df\_kp41.loc[i, "kode"].astype(int)))
In [ ]: # for i in range(len(df_kp41)):
               riau_kons.loc[riau_kons['renum'] == df_kp41.loc[i, "renum"], 'kons_' + str(df_kp41.loc[i, "kode"].astype(int))] = 1
In [ ]: # riau_kons.head()
In [ ]: # riau_kons.to_csv('riau_kons.csv', index = False, header=True)
```

riau kons 42 dari kp42

```
In [ ]: # riau_kons_42 = pd.DataFrame(riau_rt["renum"], columns=['renum'])
# riau_kons_42.head()

In [ ]: # for x in range(189,311):
# riau_kons_42['kons_'+ str(x)] = 0
# riau_kons_42.shape

In [ ]: # riau_kons_42.head()

In [ ]: # for i in range(len(df_kp42)):
# riau_kons_42.loc[riau_kons_42['renum'] == df_kp42.loc[i, "renum"], 'kons_' + str(df_kp42.loc[i, "kode"].astype(int))] = 1

In [ ]: # riau_kons_42.head()

In [ ]: # riau_kons_42.to_csv('riau_kons_42.csv', index = False, header=True)
```